研报观点知识库方案（基于 MiroFish 改造）

1. 目标

面向 `/hdd/project/Investment/32 | 通用爬虫/32.1 | wisburg智堡/omni_exports/ai_article` 目录中的大量研究报告 Markdown，建设一个可检索、可追溯、可做时间对比的知识库。

知识库核心内容分为四类：

- 事件 `Event`
- 数据 `Data / Observation`
- 观点 `Viewpoint`
- 对象 `Object`

目标查询能力：

1. 给每篇报告提取作者、机构、发布时间、核心事件、关键观点、关键数据。
2. 能按作者或机构检索历史观点。
3. 能围绕某个事件查看不同人的观点分布与时间变化。
4. 能把观点和证据、数据、原文出处关联起来，保证可回溯。

2. 对当前项目的判断

MiroFish 当前项目适合复用的部分：

- Markdown 读取与文本预处理
- 长文分块
- 图谱存储与 GraphRAG 检索
- 报告式总结与问答
- 时序边字段与历史事实检索

PROF

不建议直接沿用的部分：

- 自动本体生成作为长期知识库 schema 入口
- 多 Agent 仿真主链路
- 纯“模拟世界”导向的图谱语义

原因：

- 研报知识库需要稳定 schema，不适合每批文档重新生成本体。
- 当前项目的自动本体生成有截断策略，更适合临时任务，不适合长期库。
- 当前最值得保留的是图谱与 GraphRAG，不是仿真。

因此建议路线是：

保留 MiroFish 的图谱、检索、报告能力，替换为固定的“研报知识库 schema”。

3. 为什么不能只做“时序图节点 RAG”

如果只做时序图节点 RAG，会有两个问题：

1. 观点 / 事件 / 对象 很适合图，但 数据 不全适合直接做图节点。
2. 金融报告中的很多“关键数据”不是简单时间序列点，而是带上下文的结构化事实。

例如：

- 干预警报级别 = 4/5
- 美元/日元关键水平 = 161.95
- 每 100 亿美元干预可带来 1.8% 或 2.2% 的汇率影响
- 42.5% 的受访者预计 162 附近发生干预

这些内容包含：

- 等级型数据
- 阈值型数据
- 调查统计
- 规则/弹性估计
- 时点存量

它们不应全部压成单一的 `value + timestamp`。

所以建议采用混合架构：

- 图谱：承载事件、对象、观点、数据语义关系
- 结构化数据表：承载数值字段和可筛选字段
- 文档分块：承载证据文本与引用原文

4. 总体架构

建议采用五层结构：

4.1 文档层 `Document`

每篇 md 作为一篇独立文档，保存：

- `doc_id`
- `title`
- `published_at`
- `author`
- `institution`
- `source`
- `detail_type`
- `file_path`
- `platform`

这层优先从 Markdown front matter 解析，不依赖 LLM。

4.2 证据层 `EvidenceChunk`

将正文切分为 chunk，保留：

- `chunk_id`
- `doc_id`
- `chunk_index`
- `text`
- `section`
- `char_start`
- `char_end`

作用：

- 支持 GraphRAG
- 支持精确引用
- 支持回溯观点和数据来自哪里

4.3 语义图层 `Graph`

图谱承载以下核心节点：

- `Document`
- `Object`
- `Event`
- `Viewpoint`
- `Observation`
- `DataSeries`

4.4 时间层 `Temporal`

所有可变知识都尽量带时间字段：

- `published_at`
- `event_time`
- `observation_time`
- `valid_from`
- `valid_to`
- `created_at`

4.5 数值层 `Structured Store`

真正需要做筛选、排序、聚合的数据放结构化表，不强迫全部走图。

适合放表里的内容：

- 数值
- 单位
- 时间
- 调查占比
- 估算值

PROF

- 阈值
- 方法说明

5. 固定知识 schema

5.1 Document

表示一篇研究报告。

关键字段：

- `doc_id`
- `title`
- `published_at`
- `author_name`
- `institution_name`
- `source_id`
- `detail_type`
- `platform`
- `file_path`

5.2 Object

统一表示“对象”。建议子类型：

- `Person`
- `Institution`
- `Company`
- `Government`
- `CentralBank`
- `Asset`
- `Region`
- `CurrencyPair`

PROF

关键字段：

- `object_id`
- `name`
- `object_type`
- `aliases`
- `country`
- `description`

5.3 Event

表示一个可被多人讨论、并且可做时间跟踪的事件。

建议子类型：

- `PolicyEvent`

- `MacroEvent`
- `MarketEvent`
- `EarningsEvent`
- `InterventionEvent`

关键字段：

- `event_id`
- `canonical_name`
- `event_type`
- `start_time`
- `end_time`
- `status`
- `aliases`
- `summary`

5.4 Viewpoint

表示“某人/某机构对某事件/对象的一个观点”。

关键字段：

- `viewpoint_id`
- `summary`
- `stance`
- `polarity`
- `confidence`
- `published_at`
- `source_doc_id`
- `author_object_id`
- `target_event_id`
- `quote_span`

PROF

其中：

- `stance` 适合表达支持/反对/谨慎/看多/看空/中性等
- `summary` 是对观点的一句结构化摘要
- `quote_span` 用于回溯原文

5.5 Observation

表示一条“结构化数据事实”，是本方案中最关键的数据节点。

不要把它简单理解为时序点。它可以表示：

- 等级
- 阈值
- 调查结果
- 估算值

- 存量值
- 规则/弹性估计

关键字段建议：

- `observation_id`
- `observation_type`
- `metric_name`
- `subject`
- `value_num`
- `value_text`
- `unit`
- `as_of_date`
- `method`
- `qualifier`
- `source_doc_id`
- `source_quote`

建议的 `observation_type`：

- `level`
- `threshold`
- `estimate`
- `survey_stat`
- `stock`
- `flow`
- `ratio`
- `scenario_rule`

5.6 DataSeries

表示真正可长期观测的序列概念。

PROF

例如：

- `USDJPY`
- `Japan_FX_Reserves`
- `BOJ_Policy_Rate`

关键字段：

- `series_id`
- `name`
- `frequency`
- `unit`
- `subject`
- `description`

6. 边关系设计

建议核心边如下：

- `Document AUTHORED_BY Object(Person)`
- `Document PUBLISHED_BY Object(Institution)`
- `Document HAS_VIEWPOINT Viewpoint`
- `Document HAS_OBSERVATION Observation`
- `Viewpoint BY Object`
- `Viewpoint ABOUT Event`
- `Viewpoint ABOUT Object`
- `Viewpoint SUPPORTED_BY Observation`
- `Observation ABOUT Event`
- `Observation ABOUT Object`
- `Observation OF_SERIES DataSeries`
- `Event INVOLVES Object`
- `Document MENTIONS Event`
- `Document MENTIONS Object`
- `EvidenceChunk SUPPORTS Viewpoint`
- `EvidenceChunk SUPPORTS Observation`

这样能够支持：

- 从人找观点
- 从事件找多方观点
- 从观点追证据和数据
- 从数据回溯具体文档和作者

7. “关键数据”怎么处理

示例：

- 干预警报级别：4级（共5级）
- 美元/日元关键水平：161.95
- 每100亿美元干预 -> 汇率下降 1.8% / 2.2%
- 干预资金规模：1870亿美元
- 42.5% 受访者预计在 162 左右发生干预
- 外汇储备总额：1.2 万亿美元

这些都不应强行压成普通时序点，而应入库为 `Observation`。

建议拆法：

7.1 等级型

- `metric_name = intervention_alert_level`
- `observation_type = level`
- `value_num = 4`
- `qualifier = 5级体系`

7.2 阈值型

PROF

- `metric_name = usd_jpy_key_level`
- `observation_type = threshold`
- `value_num = 161.95`

7.3 规则/弹性型

- `metric_name = usd_jpy_intervention_effect`
- `observation_type = scenario_rule`
- `value_text = 每100亿美元干预 -> -1.8%`
- `method = 日度数据`

再建第二条：

- `value_text = 每100亿美元干预 -> -2.2%`
- `method = 日内高频数据`

7.4 存量型

- `metric_name = intervention_capacity_usd`
- `observation_type = stock`
- `value_num = 1870`
- `unit = 亿美元`

7.5 调查统计型

- `metric_name = expected_intervention_level_share`
- `observation_type = survey_stat`
- `value_num = 42.5`
- `unit = percent`
- `qualifier = 预计162左右发生干预`

7.6 时间点存量

PROF

- `metric_name = fx_reserve_total`
- `observation_type = stock`
- `value_num = 1.2`
- `unit = trillion_usd`
- `as_of_date = 2025-12-31`

8. 入库流程

建议分为 6 步。

第 1 步：解析 Markdown front matter

优先解析：

- `title`
- `published`

- `institution`
- `author`
- `source`
- `detail_type`

这一层不要先用 LLM，因为样本里已经是结构化字段。

第 2 步：正文切块

保留章节结构与 chunk id，用于：

- 证据回溯
- 向量检索
- 后续观点和数据抽取

第 3 步：事件 / 对象 / 数据 / 观点抽取

建议采用固定 prompt 和固定输出 schema，而不是重新生成本体。

输出对象：

- `objects.json`
- `events.json`
- `viewpoints.json`
- `observations.json`

第 4 步：归一化与去重

关键工作：

- 同一作者名归一化
- 同一机构名归一化
- 同一事件别名归一化
- 同一货币对、同一指标归一化

PROF

例如：

- “日元购买干预”
- “日元干预”
- “外汇干预”

需要尽量归并为同一事件簇或同一 canonical event。

第 5 步：写入图谱与结构化表

建议双写：

- 写入图谱：语义关系
- 写入表：数值、时间、筛选字段

第 6 步：建立检索层

检索分两类：

- 图检索：查关系、查主题、查跨文档连接
- 结构化检索：查数值、查时间、查作者、查事件

最后由 ReportAgent 或问答层进行总结输出。

9. 查询能力设计

9.1 查询作者历史观点

查询意图：

- `Goto 历史上关于日元干预的观点有哪些？`

底层路径：

- `Person -> Viewpoint -> Document`
- 再按 `published_at` 排序

9.2 查询事件上的多方观点

查询意图：

- `围绕日元购买干预，各家机构观点分别是什么？`

底层路径：

- `Event -> Viewpoint -> Person / Institution`

9.3 查询观点变化

查询意图：

- `某作者对日本央行干预的判断是如何变化的？`

PROF

底层路径：

- 固定 `author + event`
- 拉出所有 `Viewpoint`
- 按时间排序
- 比较 `summary / stance / supporting observations`

9.4 查询某观点引用的数据

查询意图：

- `这条观点背后的关键数据有哪些？`

底层路径：

- `Viewpoint -> Observation -> Document / EvidenceChunk`

10. 与当前 MiroFish 的改造建议

10.1 建议保留

- 文件读取与预处理
- 长文分块
- 图谱存储
- GraphRAG 检索
- 报告 Agent 的总结能力

10.2 建议替换

- 自动本体生成 -> 固定知识库 schema
- 仿真主链路 -> 研报入库主链路
- 模拟 Agent -> 观点/事件/数据抽取器

10.3 建议新增

- front matter 解析器
- 结构化 schema 导出器
- 事件归一化模块
- 作者/机构消歧模块
- Observation 结构化表
- 面向研报场景的查询 API

11. 分阶段实施建议

阶段一：最小可用版本

目标：

- 解析 md front matter
- 生成 `Document / Person / Institution`
- 抽取 `Event / Viewpoint`
- 支持按作者查观点

阶段二：加入数据层

目标：

- 抽取 `Observation`
- 建立 Observation 表
- 支持观点 -> 数据 -> 原文回溯

阶段三：加入时间演化能力

目标：

- 事件归一化
- 观点时间轴

PROF

- 事件上的多方观点变化分析

阶段四：加入高质量问答与报告

目标：

- 基于 GraphRAG + Structured Query 的混合问答
- 自动生成“作者观点演进报告”
- 自动生成“事件多方观点对比报告”

12. 最终结论

这个知识库方案最合适的形态，不是纯文档 RAG，也不是纯时序图节点 RAG，而是：

固定 schema 的研究报告知识图谱 + 结构化 Observation 数据层 + 证据级文档分块检索。

一句话总结：

- 事件 / 对象 / 观点 主要放图谱
- 关键数据 主要放 Observation + 结构化表
- 原文证据 保留在 chunk 层
- 问答和总结 用 GraphRAG + ReportAgent 完成